

周宁思远-Agent 工程师-4年经验

18978330270 | zhouningsiyuan@foxmail.com | 上海
blog: soyor.in



个人总结

具备 4 年研发经验，3 年大模型与 AI Agent 平台核心研发经验。现任中远海运科技算法工程师兼部门大模型方向技术负责人，能持续关注前沿开源技术、学术进展与 AI-Native 研发模式，具备出色的团队领导力、跨部门协同与技术汇报能力。

专业技能

- 开发语言**：精通 Python / Java / JS / Golang 前后端全栈开发，擅长跨技术栈整合，具备大型数字系统的开发经验和复杂数据库建模能力。有良好技术选型品味
- Agent 工程与架构**：深入掌握 ReAct、Multi-Agent 架构，精通 RAG / GraphRAG 的基本原理，具备自研 AgentLoop、沙盒环境、智能体验证的实战经验
- 大模型与推理引擎**：深入理解大模型架构与微调（SFT）原理。熟悉主流模型推理优化机制（Continuous Batching, Chunked Prefill, Page Attention, Flash Attention 等）；熟悉 vLLM 的原理和部署，熟悉模型压缩、量化的相关技术与显存、吞吐量调优。
- 深度学习**：精通 Pytorch 与 Transformer 库，熟悉 YOLO、UNet 等视觉算法与 XGBoost 等机器学习算法，具备完整的算法落地与部署经验。

教育经历

上海海事大学 双一流

2018年09月 - 2022年07月

计算机科学与技术 本科 全日制

在校期间成绩优异，积极参加课题组和竞赛，并在蓝桥杯、全国大学生计算机设计大赛、数学建模、网络攻防等比赛中获得国家级奖项。

工作经历

中远海运科技股份有限公司

2022年10月

AI Agent 平台技术负责人

主导部门级企业 Agent Runtime 框架及核心沙盒系统从 0 到 1 建设，负责总体架构设计、技术选型、核心模块研发及研发推进，承担约 90% 核心代码开发。带领 8 人研发团队完成平台落地，确立部门 AI-Native 基础设施。平台覆盖超 10 万名员工，推动核心工作流迁移，AI 平台日均使用时长占整体业务系统 40% 以上。

项目经历

部门企业级 Agent Runtime 框架平台

主导从 0 到 1 建设统一的企业级 Agent 基础设施，项目参考 Google NotebookLM 和 Hermes，承担约 80% 核心模块研发

- 自研平台**：基于 Python 及 ReAct 原理自研 AgentLoop 运行时，独立设计开发会话管理、MCP、Skills 等核心体系；参考 Claude Code 设计 Memory 模块，借鉴 LLM Wiki、GraphRAG，构建改进知识库。
- Agent Harness**：面向 Agent 的工具调用与代码执行过程设计 Harness，使 Agent 能够感知当前执行环境、文件状态、任务进度和运行结果，并根据执行状态等反馈继续修正任务。沙盒作为 Harness 的执行环境组成部分，为上述能力提供隔离的代码与应用运行空间。
- 沙盒系统**：基于 Docker 的 DooD 研发 Agent 沙盒，设计“创建-运行-回收-增量快照”生命周期，通过缓存池实现环境毫秒级启动，通过共享卷与动态路由机制打通 Agent 与 Next.js、Java 等执行环境的跨容器协作，并支持运行状态和编译错误回传。
- Agent 评估与自进化设计**：基于生产埋点还原用户操作链和 Agent 执行链，建立“规则真值 + LLM-as-Judge”双通道评测体系，结合任务级 Rubric、模型蒸馏验证集和 Badcase 回归，评估 Agent 的意图理解、工具调用、任务执行链和最终结果；参考 Hermes 的 Skill 自进化实践，设计由用户侧 Skill 创建与修订、中心化评估合并、验证门禁、灰度发布和回滚组成的持续改进机制。
- 业务收益**：成功打造具备 Office 编辑、Next.js 网站开发等能力的 AI 底座，支撑高速收费、智能工厂等业务，重庆单地覆盖 1 万余名员工，Agent 产品 DAU 稳定在 1000 - 2000。

高速智能问数 BI 智能体

面向高速收费每日亿级新增、总计千表规模的复杂业务数据，解决传统数据查询门槛高、跨表聚合极度依赖人工的问题。

- 复杂SQL生成**：依托 Apache Doris 宽表底座，通过 Agent 对数据库的自主探索，构建表结构说明，并进一步根据业务域，设计“表级-业务级-顶层编排”反向建模业务 skill。基于 Kimball 维度建模理论设计 few-shot 的 RAG 查询方案。
- 语音校正**：平台接入 ASR+VAD 实现语音识别，并用小参数模型实现意图识别；微调 NER 实现实体识别，结合 RAG 校准特殊名词的关键含义和字典术语。
- 数据飞轮与双通道评测**：建立“规则真值 + LLM-as-Judge”评测体系，结合自定义任务级 Rubric 评估 Agent 意图与执行链。采集业务系统的埋点数据，结合构建的检索维度，蒸馏 deepseek 合成验证集，解决难例增广和 bad case 修正，形成持续迭代的数据飞轮闭环。
- 业务收益**：产品在双盲测验中 SQL 编写与数据查询质量逼近人工分析基线的时候，整体分析效率提升 10 倍。

贵州高速智能稽核 Multi-Agent

面向贵州高速逃费稽核场景，结合传统机器学习、数据分析与大模型能力，解决复杂新型逃费策略难以仅靠规则覆盖的问题。

- MAS 研判链路**：创新设计“特征工程 + XGBoost 粗筛 + Multi-Agent 深度研判”架构，主导构建“编排-数据准备-研判-Critic”四阶段智能体工作流，实现灰度逃费样本的深度分析与动态的规则更新，有效解决无效查询、上下文拥挤与研判漂移等工程问题。
- 业务收益**：系统日均精准输出约 100 辆违规车辆及完整证据链，试运行期间累计追缴金额近 100 万元，并成功挖掘出新型逃费策略及团伙作案线索

集团审计违规分类模型微调

针对集团审计 171 个边界模糊、长尾分布的细粒度违规类别，在标注数据极少的冷启动条件下完成高精度分类模型自研与落地。

- 引入 DSPy 构建启发式语义规则系统，将基线准确率从 34% 提升至 56%；通过分析 Trace 并经由人工调整得到高质量的数据，基于 DeepSpeed 与 TRL 对 Qwen3-4B 进行 QLoRA 微调，跑通“规则迭代-Trace 沉淀-模型训练”的 AI 研发闭环。
- 基于 vLLM 和 4 张 NVIDIA A6000 完成私有化推理部署，围绕 TTFT、TPOT 与吞吐量进行压测与调优。
- 业务收益**：最终模型分类准确率提升至 80%，显著提升审计部门工作效率与定性准确度。